

Lernmodul FSTI-160:
**Computer Vision vertiefend verstehen,
anwenden und entwickeln**

Block 2: Lokalisation

13.05.2026, 17:15-20:30 Uhr

- Wie ist ein Convolutional Neural Network aufgebaut?

- Wie ist ein Convolutional Neural Network aufgebaut?
 - Netzwerk mit verschiedenen Schichten/Layern
 - Beispiele für Schichten/Layer
 - Convolution/Faltungs-Layer (Conv)
 - Pooling-Layer
 - ReLU-Layer
 - Flatten Layer
 - Fully Connected Layer (FC)
 - Softmax Layer
- Welche Layer waren für uns die wichtigen Layer? Woran sieht man das?

- Wie ist ein Convolutional Neural Network aufgebaut?

- Netzwerk mit verschiedenen Schichten/Layern
- Beispiele für Schichten/Layer
 - **Convolution/Faltungs-Layer (Conv)**
 - **Pooling-Layer**
 - ReLU-Layer (wird hier weg gelassen)
 - **Flatten Layer**
 - **Fully Connected Layer (FC)**
 - **Softmax Layer**

Gewichtet, Features &
Entscheidungen

Ungewichtet,
Verarbeitung

- Welche Layer waren für uns die wichtigen Layer? Woran sieht man das?

- Was machen diese Layer?
 - **Convolutional Layer**

- Was machen diese Layer?
 - **Convolutional Layer**
 - Faltungs-Kernel um Features zu extrahieren
 - Viele verschiedene Kernel in jedem Layer
 - Ergebnis von jedem Filter: Feature Map
 - Mehr Layer = Komplexere Features (bis hin zu komplexen Objekten)
 - Viele Daten, daher ggf. Pooling Layer zur Datenreduktion nötig
 - **Leitfrage:**

- Was machen diese Layer?
 - **Convolutional Layer**
 - Faltungs-Kernel um Features zu extrahieren
 - Viele verschiedene Kernel in jedem Layer
 - Ergebnis von jedem Filter: Feature Map
 - Mehr Layer = Komplexere Features (bis hin zu komplexen Objekten)
 - Viele Daten, daher ggf. Pooling Layer zur Datenreduktion nötig
 - **Leitfrage:** Welche Features tauchen auf und lassen sich grundsätzlich unterscheiden?

- Was machen diese Layer?
 - **Fully Connected Layer**


- Was machen diese Layer?
 - **Fully Connected Layer**
 - Alle Neuronen sind miteinander verknüpft (wie klassisches Perzeptron)
 - Hier werden die Features mit den Klassen verknüpft
 - Letzter Layer: So viele Neuronen wie Klassen unterschieden werden sollen
 - **Leitfrage:**

- Was machen diese Layer?
 - **Fully Connected Layer**
 - Alle Neuronen sind miteinander verknüpft (wie klassisches Perzeptron)
 - Hier werden die Features mit den Klassen verknüpft
 - Letzter Layer: So viele Neuronen wie Klassen unterschieden werden sollen
 - **Leitfrage:** Welche Ausprägung & Kombination der Features gehört zu welcher Klasse?


- Was machen diese Layer?
 - **Pooling Layer**
 - **Flatten**
 - **Softmax**

- Was machen diese Layer?
 - **Pooling Layer**
 - Nur für Reduktion der Datenmenge, nach Conv-Layern
 - Beispiele: Average Pooling und Max Pooling
 - Für Klassifikation speziell: Max-Pooling weil Features gesucht/erhalten werden
 - Avg Pooling wird eher für andere CV-Aufgaben genutzt, z.B. Segmentierung
 - **Flatten**
 - Nur Vorbereitung von Conv/Pooling zu FC Layer
 - FC erwartet 1D-Daten, Feature Map aus Conv/Pooling immer 3D/2D, daher Umwandlung
 - **Softmax**
 - Schließt FC ab, macht aus Klassen Werte für Wahrscheinlichkeit (Normierung auf 0-1)



Erinnerung: Typischer Aufbau eines CNNs:



Fully Connected Layer



Wie bewerte ich die Performance meines trainierten CNNs




Verständnisfragen: Metriken zur Bewertung von Klassifizierung

- Warum ist Accuracy allein oft nicht ausreichend, und warum hilft die Konfusionsmatrix hier?
- Wie würdest du erkennen, ob das Modell eine Klasse „bevorzugt“?
- Welche Werte der Matrix sind „richtig“, und welche „falsch“?

Verständnisfragen: Metriken zur Bewertung von Klassifizierung

- Warum ist Accuracy allein oft nicht ausreichend, und warum hilft die Konfusionsmatrix hier?
 - Accuracy kann irreführend sein, wenn Klassen unausgeglichen sind. Die Konfusionsmatrix zeigt, welche Klassen gut oder schlecht erkannt werden.
- Wie würdest du erkennen, ob das Modell eine Klasse „bevorzugt“?
 - Viele Vorhersagen fallen in eine bestimmte Spalte → Modell ist tendenziell voreingenommen gegenüber dieser Klasse.
- Welche Werte der Matrix sind „richtig“, und welche „falsch“?
 - Diagonale: richtig, Off-Diagonal: falsch

Überleitung: Training eines CNNs



- Wie funktioniert das Training eines CNNs?
- Wie sind die Gewichte der Neuronen zu Beginn meines Trainings?

Überleitung: Training eines CNNs

Ablauf:

1. Vorwärtsthroughlauf (Forward Pass)
2. Fehler berechnen
3. Rückwärtsthroughlauf (Backpropagation)

Epoche: Alle Daten (Batches) durch

Überleitung: Training eines CNNs

Ablauf:

1. Vorwärtsthroughlauf (Forward Pass)

- Das Netz bekommt eine Eingabe (Alle Daten oder Batch)
- Die Eingabe wird Schicht für Schicht weitergereicht
- Am Ende kommt eine Vorhersage raus

2. Fehler berechnen

- Das Netz vergleicht die Vorhersage mit dem richtigen Wert (Label)
- Wir erhalten den „Fehler“

3. Rückwärtsthroughlauf (Backpropagation)

- Der Fehler wird „zurückgeschickt“
- Jede Schicht schaut: „Wie viel habe ich zum Fehler beigetragen?“
- Die Gewichte werden angepasst, damit der Fehler beim nächsten durchlauf kleiner wird

Epoche: Alle Daten (Batches) durch

- Was ist Transfer Learning?

- Was ist Transfer Learning?
 - Wir nehmen ein vortrainiertes Netz
 - Passen nur spätere Schichten und ggf. Gewichtungen an
 - Varianten:
 1. Feature Extraction: Kein neues Training, nur Anwendung (letzte Schicht anpassen in Zahl)
 2. Fine Tuning: neues Training:
 - a) FC Gewichte,
 - b) Alle Gewichte (FC & Conv)

- Wann wird welche Variante davon genutzt und was ist zu beachten?
 1. Feature Extraction:
Kein neues Training, nur Anwendung (letzte Schicht anpassen in Zahl)
 2. Fine Tuning:
neues Training, a) FC Gewichte, b) Alle Gewichte (auch Conv)

- Wann wird welche Variante davon genutzt und was ist zu beachten?
 1. Feature Extraction:
Kein neues Training, nur Anwendung (letzte Schicht anpassen in Zahl)
 - Daten sind sehr ähnlich zu „Ursprungsdaten“ des Vor-Trainings
 - Schnell, aber schlechte Ergebnisse, wenn Daten sehr anders
 2. Fine Tuning:
neues Training, a) FC Gewichte, b) Alle Gewichte (auch Conv)
 - a) Ähnliche Kombination Ausprägungen von Features zu erwarten, aber Features selbst gleich
 - b) Features & Ausprägung & Kombination kann anders sein
 - Bessere Ergebnisse, aber mehr Daten nötig und mehr Rechenaufwand


- Was macht eine Residual Connection?
- Warum braucht man das?

- Was macht eine Residual Connection?
 - Sie schiebt den Input auch als Information mit durch das Netz
 - „Skip“-Connection
- Warum braucht man das?
 - Es gehen bei Backpropagation Informationen verloren
 - Mehr Layer (=tiefere Netze) führt in manchen Fällen zu schlechteren Ergebnissen
 - Idee: Information mitgeben, stabileres Training
 - Layer ohne: $\text{Output} = F(x)$
 - Layer mit Residual: $\text{Output} = F(x) + x$
 - D.h. falls $F(x) = 0$, ist trotzdem noch Information (x) vorhanden und wird weiter gegeben in Netz, ohne ist ab 0 der „Strang“ danach immer 0

- Gemeinsame Besprechung der Projekte
- Wechsel zu Mentimeter

- Verständnis: Was ist Overfitting/Underfitting?

- Verständnis: Was ist Overfitting/Underfitting?



- Verständnis: Was ist Overfitting/Underfitting?
 - Underfitting:
 - Das Modell ist nicht komplex genug
 - Trainingsfehler und Generalisierungsfehler sind beide recht groß
 - Overfitting:
 - Das Modell ist zu komplex
 - Der Trainingsfehler ist klein, während der Generalisierungsfehler wieder wächst.
 - Das Modell ist zu stark an die Trainingsdaten angepasst, es kann nicht „generalisieren“
- Nebenfrage: Was ist der Generalisierungsfehler?

- Verständnis: Was ist Overfitting/Underfitting?
 - Underfitting:
 - Das Modell ist nicht komplex genug
 - Trainingsfehler und Generalisierungsfehler sind beide recht groß
 - Overfitting:
 - Das Modell ist zu komplex
 - Der Trainingsfehler ist klein, während der Generalisierungsfehler wieder wächst.
 - Das Modell ist zu stark an die Trainingsdaten angepasst, es kann nicht „generalisieren“
- Nebenfrage: Was ist der Generalisierungsfehler?
 - Der Generalisierungsfehler ist der Fehler auf den Testdaten

- Leitfrage: Warum reicht Klassifikation nicht mehr aus?



- Erinnerung: Die drei Hauptaufgaben von angewandter Computer Vision:

Aufgabe	Frage
Klassifikation	
Lokalisierung	
Segmentierung	

- Erinnerung: Was wir ganz am Anfang schonmal besprochen hatten:

Aufgabe	Frage
Klassifikation	Was ist es?
Lokalisierung	Wo ist es?
Segmentierung	Welcher Pixel gehört dazu?

- Erinnerung: Was wir ganz am Anfang schonmal besprochen hatten:

Aufgabe	Frage
Klassifikation	Was ist es?
Lokalisierung	Wo ist es?
Segmentierung	Welcher Pixel gehört dazu?

- Wie kann man beschreiben, WO ein Objekt ist?


Beispiel: Wo ist der Stuhl




- Wie kann man beschreiben, WO ein Objekt ist?



Mittelpunkt




Mehrere Punkte



Rechteck

- Woher weiß ich, ob meine Beschreibung gut ist? Was kann schief gehen?



Mittelpunkt



Mehrere Punkte



Rechteck



- **Wie kann man beschreiben, WO ein Objekt ist?**

- Mittelpunkt
- Mehrere Punkte
- Rechteck (oder andere mathematisch beschreibbare Form)

- **Woher weiß ich, ob meine Beschreibung gut ist?**
Was kann schief gehen?

- Zu groß?
- Zu klein?
- Zu viel Hintergrund dabei?
- Objekt nicht vollständig abgebildet oder abgeschnitten?
- Mehrere Objekte mit drin?

Aufbau einer Bounding Box:

Variante 1	Variante 2
$x, y, \text{Breite}, \text{Höhe}$  The diagram shows an orange rectangle on a light gray background. A horizontal line with arrows at both ends is positioned above the rectangle, indicating its width. A vertical line with arrows at both ends is positioned to the left of the rectangle, indicating its height. The top-left corner of the rectangle is aligned with the intersection of these two lines.	$x_{\min}, y_{\min}, x_{\max}, y_{\max}$  The diagram shows an orange rectangle on a light gray background. A horizontal line with arrows at both ends is positioned above the rectangle, indicating its width. A vertical line with arrows at both ends is positioned to the left of the rectangle, indicating its height. The top-left corner of the rectangle is marked with a blue 'X' at the intersection of the width and height lines.


Frage: Warum beginnen wir mit der Bounding Box oben links?

- Nächster Schritt: Wann ist eine vorhergesagte Bounding Box gut?
 - Überlegung: Was lernt unser Netz?

- Nächster Schritt: Wann ist eine vorhergesagte Bounding Box gut?
 - Überlegung: Was lernt unser Netz?




- Nächster Schritt: Wann ist eine vorhergesagte Bounding Box gut?
 - Idee: Wir legen die Boxen übereinander.



- Was können wir hier bewerten?

- Nächster Schritt: Wann ist eine vorhergesagte Bounding Box gut?
 - Idee: Wir legen die Boxen übereinander.




Intersection over Union (IoU)

$$\text{IoU} = \frac{\text{Fläche der Überlappung}}{\text{Fläche der Vereinigung}}$$

- Was können wir hier bewerten?

- Nächster Schritt: Wann ist eine vorhergesagte Bounding Box gut?
 - Idee: Wir legen die Boxen übereinander.



Fläche
der
Über-
lappung

Fläche
der Verei-
nigung

Intersection over Union (IoU)

$$\text{IoU} = \frac{\text{Fläche der Überlappung}}{\text{Fläche der Vereinigung}}$$

Verständnis:

- Welcher Wert für IoU wäre ein guter Wert?
- Warum nehmen wir nicht einfach die Überlappung allein als Bewertungsmetrik?

Verständnis:

- Welcher Wert für IoU wäre ein guter Wert?
 - 1 (Überlappung = Gesamtfläche)
- Warum nehmen wir nicht einfach die Überlappung allein als Bewertungsmetrik?
 - Wenn nur die Überlappung verwendet ist, könnte eine viel zu große Box gut abschneiden weil die Überlappung 100% ist, dass zu viel „Hintergrund“ dabei ist wird dann nicht mitbewertet